Признаки слова заменяют часть опроса носителей

Иерархическая модель Брэдли–Терри для ранжирования татарских замен русских заимствований

Что и зачем

Задача. Упорядочить татарские замены заимствования по мнению носителей.

Проблема. Опрос носителей дорог, у новых слов нет истории оценок.

Идея. Признаки слова — априорная оценка, сравнения её уточняют.

Вопрос. Сколько сравнений экономят признаки и при каком ρ?

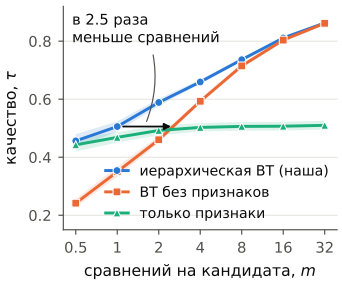
Зачем. Спланировать опрос; метод общий для попарных оценок.

Модель

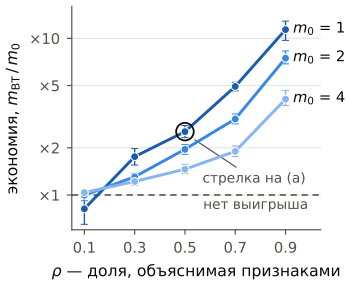
$$P(w_i \succ w_j) = \sigma(u_i - u_j), \quad u_i = \theta^\top \mathbf{x}_i + \eta_i;$$

$\mathbf{x}_i$ — признаки слова (план: «татарскость» по символьной LM, сингармонизм, длина …; в синтетике — случайные), η_i — то, что признаки не объясняют.

а) качество от бюджета, ρ = 0.5



б) экономия сравнений



Обозначения

m — сравнений на кандидата;
τ — Кендалл с истинным порядком;
ρ — доля разброса предпочтений, объяснимая признаками;
m_{BT}/m_0 — во сколько раз длиннее опрос без признаков.

Результат

При $\rho = 0.5$ одного сравнения на кандидата хватает там, где BT без признаков нужно 2.5; при $\rho = 0.9$ — в 11 раз меньше. Бесполезные признаки ($\rho = 0.1$) не помогают, а при $m = 1$ слегка мешают.

Синтетика: 40 заимствований $\times$ 8 кандидатов, 20 запусков, 95%-е ДИ.

вычисления: code/main.py · рисунок: code/plots.py